Fatemeh Maddahzadeh

AI Engineer - LLM, RAG e Sistemi Agentici
Torino, Italia | fatemeh76m@gmail.com | (+39) 351 731 1645
linkedin.com/in/f-maddahzadeh | github.com/fatemeh76m
Portfolio: fatemeh76m.github.io

Profilo

AI Engineer con quasi 3 anni su una piattaforma LLM multi-tenant in produzione, di cui sono stata la prima sviluppatrice backend: RAG su PostgreSQL/pgvector, integrazione multi-provider di LLM, tool calling e MCP, pipeline di agenti AI multi-step, streaming e guardrail per LLM. Alle spalle oltre 6 anni di sviluppo backend in Node.js/TypeScript, microservizi e cloud (GCP, Kubernetes), anche come Backend Team Leader. Tesi magistrale al Politecnico di Torino su routing e rilevamento del drift nei sistemi multi-LLM (Python, LiteLLM). Disponibile da subito.

Esperienza Professionale

- Software Engineer - Piattaforma AI/LLM presso Glue Labs

Mar. 2023 - Dic. 2025 | Torino, Italia | Part-time, durante la magistrale | Pupau (pupau.ai): piattaforma B2B multi-tenant in cui le aziende creano assistenti e agenti AI sulle proprie knowledge base, con un marketplace pubblico di assistenti.

- **Responsabilità:** prima sviluppatrice backend; ho realizzato da sola il nucleo RAG della piattaforma nei primi ~6 mesi, mantenendo poi la responsabilità del core AI (pipeline delle query, adapter LLM e di embedding, agenti, guardrail, MCP) con un team cresciuto fino a 7 sviluppatori; ~1.650 commit, seconda contributor
- **RAG e retrieval:** ingestion di documenti e pagine web con job di embedding asincroni su Google Cloud Tasks; PostgreSQL + pgvector (embeddings a 1536 dimensioni, indice IVFFlat, ricerca per similarità con soglie per assistente); chunking con tiktoken e chunk versionati (ordine, pagina, attivo/obsoleto) per la reindicizzazione senza downtime
- **Embeddings:** livello di embedding modulare con OpenAI text-embedding-3-small/-large, ada-002 e il modello open-source BAAI/bge-m3, tramite OpenAI e deployment Azure OpenAI, con una factory per la scelta del provider e il bilanciamento del carico
- **Livello multi-provider per LLM:** progettato un'unica interfaccia per OpenAI, Azure OpenAI, Anthropic, Google Gemini, Vertex AI, Groq e Mistral, con tracciamento dei costi per chiamata e metriche Prometheus sui rate limit dei provider
- **Tool calling e MCP:** sviluppato il tool calling su 5 tipi di strumenti (chiamate HTTP remote, pipeline interne, strumenti nativi, server/tool MCP) e creato l'integrazione MCP (client e configurazione per assistente); esecuzione con RxJS, retry, errori restituiti al modello come risultati strutturati e approvazione da parte dell'utente
- **Agenti AI:** creato il framework di agenti basato su "actor", poi esteso dal team a circa 30 actor (LLM, knowledge base, ricerca web, code interpreter E2B, browser use con Playwright, database, router, blocchi condizionali) concatenati in pipeline multi-step; aggiunto il tagging tra agenti
- **Streaming e qualità:** streaming con Server-Sent Events, salvataggio e cifratura opzionale; guardrail LLM su input e output; modalità "chiusa" che non risponde senza documenti rilevanti (meno allucinazioni); feedback degli utenti e log delle chiamate LLM
- **Backend e infrastruttura:** servizi NestJS, TypeORM e RxJS su GCP (GKE, App Engine); configurato i primi ambienti di staging e produzione; migrazioni del database versionate, accesso multi-tenant con API key

Ricerca AI - Tesi Magistrale

- Handoff-Aware Routing and Drift Detection for Multi-LLM Systems

2026 | Politecnico di Torino | Python | LiteLLM | valutazione di LLM

- Sviluppato un middleware in Python su LiteLLM che rileva il cambio di modello a metà conversazione (handoff) e applica strategie di mitigazione per limitare il calo di prestazioni
- Progettato una valutazione di 4 strategie di mitigazione rispetto a una baseline senza mitigazione su 400 prove con 5 LLM di 5 vendor diversi, con validatori basati su codice e un LLM-as-a-judge
- **Strategia migliore (Validation-and-Retry):** punteggio medio dei validatori 0,787 contro 0,735 della baseline, prove superate completamente 74% contro 67%, Factual Stability da 12/20 a 19/20
- Dimostrato che nessuna strategia vince su tutti gli assi e che i validatori di codice rilevano differenze che il giudice LLM non vede: la strategia va scelta in base all'aspetto di qualità più importante per ogni caso d'uso

Esperienze Precedenti

- Backend Team Leader presso Lamasoo

Gen. 2022 - Set. 2022 | Teheran, Iran | Channel manager online per il settore alberghiero, con servizi per hotel e agenzie.

- **Guidato un team di 3 sviluppatori backend:** selezione, mentoring, assegnazione dei task e valutazione dei progressi
- Pianificato sprint in Scrum, organizzato daily e revisioni, e condotto le code review
- Progettato microservizi scalabili e collaborato con il product team su priorità e risoluzione rapida dei bug

- Software Engineer presso Lamasoo

Giu. 2020 - Gen. 2022 | Teheran, Iran

- Progettato e implementato microservizi in Node.js/TypeScript e guidato il refactoring verso un'architettura a microservizi
- Sviluppato API RESTful con gli sviluppatori front-end e ottimizzato query e prestazioni del database

- Software Engineer presso Linkap

Feb. 2019 - Giu. 2020 | Teheran, Iran | Start-up IoT nel settore della domotica (smart home).

- Sviluppato il backend Node.js di un'app per smart home, integrando in tempo reale dispositivi IoT (LoRaWAN, Zigbee) con MongoDB

Istruzione

- Politecnico di Torino

Set. 2022 - Nov. 2026 (prevista) | Torino, Italia | Laurea Magistrale in Software Applications

- Media 25/30 | Tesi sui sistemi multi-LLM (vedi Ricerca AI)

- Università di Teheran

Set. 2016 - Feb. 2021 | Teheran, Iran | Laurea Triennale in Ingegneria Informatica (Software Engineering)

- **Media 16.5/20 (ultimi due anni:** 17.36/20); prima università dell'Iran secondo U.S. News
- 61ª posizione nel test nazionale di ammissione all'università

Progetto selezionato

- Mismatch Desk | github.com/fatemeh76m/mismatch-desk | Revisione AI delle discrepanze tra fatture | Progetto portfolio

- Implementata l'estrazione strutturata con OpenRouter in un servizio FastAPI e citazioni testuali esatte; i campi mancanti o ambigui vengono segnalati per la revisione umana.
- Creato un workflow LangGraph con controlli deterministici su ordini d'acquisto e consegne; i casi e lo storico append-only delle decisioni umane sono salvati in PostgreSQL con Alembic.
- Aggiunte l'estrazione di testo da PDF con pypdf e un'interfaccia di revisione Next.js. Usa dati sintetici; non approva né paga fatture automaticamente.

Competenze Tecniche

- **AI / LLM:** RAG, embeddings, ricerca vettoriale (pgvector), tool/function calling, MCP, agenti AI e pipeline multi-step, prompt engineering, guardrail per LLM, valutazione di LLM, LiteLLM, tiktoken, streaming SSE, LangGraph, OpenRouter, estrazione strutturata con evidenze, revisione human-in-the-loop
- **Provider e modelli LLM:** OpenAI, Azure OpenAI, Anthropic, Google Gemini, Vertex AI, Groq, Mistral, BAAI/bge-m3
- **Linguaggi:** TypeScript, JavaScript (Node.js), Python
- **Backend:** FastAPI, pypdf, NestJS, Express.js, TypeORM, RxJS, API REST, microservizi, processi in background e code di messaggi
- **Frontend:** HTML, CSS, React, Next.js
- **Dati:** PostgreSQL (pgvector), MongoDB, Redis, SQL, migrazioni Alembic
- **Cloud e DevOps:** Google Cloud Platform (GKE, App Engine, Cloud Build, Cloud Tasks), Kubernetes, Docker, Prometheus, Git, Linux
- **Altro:** RabbitMQ, MQTT, Scrum, Jira
- **Sviluppo assistito da AI:** Codex, Cursor

Lingue

Persiano: madrelingua | Inglese: avanzato | Italiano: intermedio